

Data: 12/05/2026

Backend: FastAPI (backend/main.py + serve.py)

Frontend: Vanilla JS (frontend/app.js)

Modello: glm-ocr:latest via Ollama

Modifiche a main.py:

- DPI ridotto 200 -> 150
- Timeout 300 -> 600 secondi
- Errore: distingue timeout da connessione

CPU: Intel i7-4700HQ (4a gen, 2013)

GPU integrata: Intel HD Graphics 4600 (1GB)

GPU discreta: NVIDIA GTX 760M (2GB) - TROPPO VECCHIA

Soluzione: GPU Cloud su RunPod

GPU: RTX 4090 (24GB, ~\$0.39/h)

Porte: 8000 (app), 11434 (Ollama), 8889 (VS Code)

URL APP:

COMANDO SSH:

DOWNLOAD APP:

Installare Ollama + glm-ocr:

```
apt install -y zstd && curl ...install.sh | sh
ollama serve > /tmp/ollama.log 2>&1 &
ollama pull glm-ocr:latest
```

Riavviare l'app:

```
cd /root/backend && unset OLLAMA_HOST
nohup python3 serve.py > /tmp/server.log 2>&1 &
```

Installare code-server:

```
curl -fsSL https://code-server.dev/install.sh | sh
nohup code-server --port 8889 --auth none --bind-addr 0.0.0.0
> /tmp/codeserver.log 2>&1 &
```

Health check:

```
curl -s http://localhost:8000/api/health
curl -s http://localhost:11434/api/tags
```

- **PERSISTENZA DATI:**
Network Volume su RunPod (10GB ~2\$/mese)
Storage -> Network Volumes -> Add Volume
- **RISPARMIO:** Stop del pod quando non usato
- **ATTENZIONE:** senza Network Volume,
fermare il pod perde TUTTI i dati
- **Salva questo riepilogo** (chat potrebbe
non essere sempre disponibile)

=== FINE RIEPILOGO ===